

LAPORAN TEKNIS PROYEK DATA SCIENCE

Burnout Risk Prediction System

Berbasis Machine Learning untuk Deteksi Dini Risiko Burnout Karyawan

Capstone Project Coding Camp 2026 | CC26-PSU335

Tema: Healthy Lives & Well-being

Coding Camp 2026 × DBS Foundation

2026

EXECUTIVE SUMMARY

Proyek ini merupakan Capstone Project Data Science dari tim CC26-PSU335 dalam program Coding Camp 2026 yang diselenggarakan oleh DBS Foundation. Proyek berfokus pada tema Healthy Lives & Well-being, dengan tujuan utama membangun sebuah sistem prediksi risiko burnout karyawan yang komprehensif berbasis Machine Learning.

Burnout karyawan merupakan fenomena kelelahan fisik dan mental yang diakibatkan oleh paparan stres kerja yang berkepanjangan dan tidak terkelola dengan baik. Dalam konteks dunia kerja modern, burnout tidak hanya berdampak pada kesehatan individu karyawan, tetapi juga menimbulkan kerugian signifikan bagi organisasi berupa penurunan produktivitas yang dapat mencapai 30 hingga 40 persen, meningkatnya angka turnover, serta biaya rekrutmen dan pelatihan yang tinggi. Sayangnya, sebagian besar organisasi masih menangani burnout secara reaktif, yakni setelah kondisi tersebut sudah terjadi dan berdampak nyata, alih-alih secara preventif melalui deteksi dini berbasis data.

Proyek ini hadir untuk menjawab kesenjangan tersebut. Dengan memanfaatkan dataset sintetis yang mencerminkan distribusi nyata dari 2.000 karyawan, tim membangun pipeline analitik end-to-end yang mencakup proses Data Wrangling, Exploratory Data Analysis (EDA), Feature Engineering, Model Development, A/B Testing, dan pengembangan serta deployment Dashboard Interaktif menggunakan Streamlit.

Temuan dan Hasil Utama

Hasil analisis menunjukkan bahwa burnout rate keseluruhan dalam dataset adalah sebesar 6,5%, dengan 129 dari 2.000 karyawan teridentifikasi mengalami burnout. Tiga faktor paling berpengaruh terhadap risiko burnout adalah StressLevel (korelasi Pearson $r = +0,321$), WorkHoursPerWeek ($r = +0,226$), dan SatisfactionLevel ($r = -0,233$). Karyawan yang bekerja lebih dari 50 jam per minggu memiliki burnout rate sebesar 13,12%, sedangkan karyawan dengan jam kerja kurang dari 40 jam per minggu tidak ada yang mengalami burnout (0,00%). Perbedaan ini terbukti signifikan secara statistik melalui A/B Testing dengan nilai $p < 0,001$.

Empat model Machine Learning dievaluasi dalam proyek ini: Logistic Regression, Decision Tree, Random Forest, dan Gradient Boosting. Model tree-based (Decision Tree, Random Forest, dan Gradient Boosting) mencapai performa sempurna dengan Accuracy, F1-Score, Precision, Recall, dan AUC-ROC masing-masing senilai 1,0000 pada test set, dengan

CV F1-Score rata-rata 0,9961 pada validasi silang 5-fold. Model terbaik yang dipilih dan disimpan dalam artifacts adalah Decision Tree berdasarkan metrik AUC-ROC tertinggi.

Dashboard interaktif berbasis Streamlit berhasil dikembangkan dengan sembilan halaman navigasi yang mencakup Overview, EDA, Explanatory Analysis, Kuesioner Kepuasan dan Stres, Prediksi Individu, Reminder Burnout, Performa Model, dan A/B Testing. Dashboard ini kemudian di-deploy ke Streamlit Cloud sehingga dapat diakses secara publik oleh seluruh pemangku kepentingan.

Aspek	Hasil
Total Karyawan dalam Dataset	2.000 karyawan
Burnout Rate Keseluruhan	6,5% (129 karyawan)
Faktor Terkuat	StressLevel ($r=+0,321$), SatisfactionLevel ($r=-0,233$), WorkHoursPerWeek ($r=+0,226$)
Model Terbaik (AUC-ROC)	Decision Tree / Random Forest / Gradient Boosting (AUC-ROC = 1,000)
Logistic Regression AUC-ROC	0,9937
A/B Test Work Hours	Burnout rate ≥ 50 jam: 13,12% vs < 40 jam: 0,00% ($p < 0,001$)
Dashboard	9 halaman interaktif, deployed ke Streamlit Cloud
Target Awal Proyek	Accuracy $\geq 85\%$, AUC-ROC $\geq 0,85$, F1 $\geq 0,70$ -SEMUA TERLAMPAUI

BAB 1 -PROBLEM DISCOVERY

1.1 Latar Belakang dan Konteks Bisnis

Burnout karyawan telah menjadi salah satu tantangan terbesar yang dihadapi oleh organisasi modern di seluruh dunia. Kondisi ini didefinisikan oleh World Health Organization (WHO) sebagai sindrom yang dihasilkan dari stres kerja kronis yang tidak berhasil dikelola, yang ditandai dengan tiga dimensi utama: perasaan kelelahan dan kehabisan energi, meningkatnya jarak mental dari pekerjaan atau perasaan negatif atau sinis terkait pekerjaan, serta berkurangnya efisiensi profesional.

Dalam dunia kerja yang semakin kompetitif dan bergerak cepat, tekanan untuk memenuhi target, jam kerja yang panjang, minimnya work-life balance, dan rendahnya kepuasan kerja berkontribusi secara signifikan pada peningkatan prevalensi burnout. Berbagai penelitian akademis menunjukkan bahwa burnout yang tidak tertangani dapat menyebabkan penurunan produktivitas karyawan hingga 30–40 persen, meningkatkan angka absenteeism, dan pada akhirnya mendorong karyawan untuk meninggalkan organisasi (turnover intention). Biaya yang dikeluarkan perusahaan untuk proses rekrutmen dan onboarding karyawan baru dapat mencapai 50–200 persen dari gaji tahunan satu karyawan.

Tantangan utama dalam penanganan burnout terletak pada sifatnya yang seringkali tidak terlihat secara eksplisit hingga kondisinya sudah sangat parah. Banyak karyawan tidak secara terbuka mengungkapkan kondisi mental mereka karena stigma sosial, rasa takut terhadap penilaian negatif dari atasan, atau bahkan karena mereka sendiri belum menyadari bahwa mereka sedang mengalami burnout. Di sinilah peran Data Science dan Machine Learning menjadi sangat relevan: membangun sistem yang mampu mendeteksi potensi burnout secara dini berdasarkan pola data objektif dari karyawan.

1.2 Identifikasi Permasalahan

Melalui proses diskusi tim dan kajian literatur yang mendalam, tiga permasalahan utama berhasil diidentifikasi dalam konteks manajemen kesehatan karyawan di organisasi modern:

- Permasalahan Pertama (P1): Beban kerja berlebih tanpa sistem monitoring yang memadai. Banyak organisasi tidak memiliki mekanisme yang terstruktur untuk memantau beban kerja karyawan secara real-time, sehingga kondisi overwork sering tidak terdeteksi hingga berdampak pada kesehatan mental karyawan.

- Permasalahan Kedua (P2): Tidak adanya mekanisme deteksi dini burnout berbasis data. Pendekatan yang ada saat ini sebagian besar bersifat subjektif dan mengandalkan laporan mandiri karyawan atau observasi manajer, yang rentan terhadap bias dan keterlambatan deteksi.
- Permasalahan Ketiga (P3): Intervensi HR yang bersifat reaktif, bukan preventif. Departemen HR cenderung merespons masalah burnout setelah karyawan sudah menunjukkan gejala berat atau bahkan setelah mengajukan resign, bukan sebelumnya.

1.3 Solusi yang Dipilih

Setelah melakukan evaluasi komprehensif terhadap ketiga permasalahan tersebut dari sisi urgensi, dampak, dan feasibilitas penyelesaiannya dengan pendekatan Data Science, tim memutuskan untuk berfokus pada Permasalahan Kedua (P2) sebagai solusi utama proyek ini. Alasan utamanya adalah bahwa P2 merupakan akar dari P1 dan P3: jika sistem deteksi dini berbasis data berhasil dibangun, maka permasalahan monitoring (P1) dan reaktifitas intervensi (P3) dapat secara bersamaan diatasi.

Solusi yang dikembangkan adalah Burnout Risk Prediction System, sebuah sistem prediksi risiko burnout berbasis Machine Learning yang mampu mengklasifikasikan risiko burnout seorang karyawan menjadi tiga kategori: Rendah, Sedang, atau Tinggi, berdasarkan data profil karyawan dan kondisi kerjanya. Sistem ini dilengkapi dengan dashboard interaktif berbasis Streamlit yang memungkinkan tim HR, manajer, dan karyawan secara individual untuk mengakses insight dan melakukan prediksi secara mandiri.

1.4 Stakeholder dan Target Pengguna

Sistem yang dikembangkan dirancang untuk memenuhi kebutuhan tiga kelompok stakeholder utama. Pertama, HR Manager yang membutuhkan pandangan menyeluruh tentang kondisi kesehatan mental karyawan di seluruh organisasi untuk merancang program wellness yang tepat sasaran. Kedua, Manajer Tim yang perlu mengidentifikasi anggota tim yang berisiko tinggi mengalami burnout untuk dapat memberikan dukungan atau penyesuaian beban kerja secara proaktif. Ketiga, Karyawan Individual yang dapat menggunakan sistem ini sebagai alat self-assessment untuk memahami tingkat risiko burnout mereka sendiri dan mendapatkan rekomendasi wellness yang dipersonalisasi.

1.5 Success Metrics

Sejak awal proyek, tim menetapkan target performa model yang terukur dan jelas sebagai kriteria keberhasilan. Ketiga metrik berikut ditetapkan sebagai batas minimum yang harus dicapai:

Metrik	Target Minimum	Hasil Aktual	Status
Model Accuracy	$\geq 85\%$	100,00% (tree-based)	TERLAMPAUI
AUC-ROC Score	$\geq 0,85$	1,0000 (tree-based)	TERLAMPAUI
F1-Score	$\geq 0,70$	1,0000 (tree-based)	TERLAMPAUI

BAB 2 -BUSINESS UNDERSTANDING

2.1 Problem Statement

Pernyataan masalah yang menjadi fondasi seluruh proyek ini adalah sebagai berikut: Burnout karyawan tidak terdeteksi secara dini, menyebabkan penurunan produktivitas dan meningkatnya tingkat turnover dalam organisasi. Diperlukan sebuah sistem prediksi berbasis data yang dapat mengidentifikasi karyawan berisiko tinggi mengalami burnout sebelum kondisi tersebut mencapai tahap kritis.

2.2 Business Questions

Untuk memastikan analisis yang dilakukan terarah dan mampu menjawab kebutuhan bisnis secara menyeluruh, tim mendefinisikan tujuh pertanyaan bisnis yang tersusun secara berjenjang dari pertanyaan deskriptif umum hingga pertanyaan analitik yang spesifik:

Kode	Level	Pertanyaan Bisnis
BQ1	Umum	Seberapa besar proporsi karyawan yang mengalami burnout?
BQ2	Umum	Bagaimana distribusi burnout di antara berbagai peran pekerjaan (JobRole)?
BQ3	Umum	Apakah ada perbedaan tingkat burnout antara karyawan laki-laki dan perempuan?
BQ4	Menengah	Apakah beban kerja (WorkHoursPerWeek) berkorelasi signifikan dengan burnout?
BQ5	Menengah	Bagaimana kombinasi stres tinggi dan jam kerja panjang memengaruhi risiko burnout?
BQ6	Spesifik	Faktor apa yang paling berpengaruh terhadap prediksi risiko burnout karyawan?
BQ7	Spesifik	Apakah kepuasan kerja rendah secara konsisten berkorelasi dengan stres dan burnout tinggi?

2.3 Objectives

Berdasarkan problem statement dan business questions yang telah didefinisikan, proyek ini memiliki lima objektif utama yang ingin dicapai:

1. Melakukan analisis eksploratif yang komprehensif terhadap dataset burnout karyawan untuk memahami pola, distribusi, dan hubungan antar variabel.
2. Membangun model Machine Learning yang mampu memprediksi risiko burnout karyawan dengan tingkat akurasi, F1-Score, dan AUC-ROC yang melampaui target yang ditetapkan.
3. Mengidentifikasi faktor-faktor paling signifikan yang berkontribusi terhadap burnout karyawan melalui analisis feature importance dan A/B Testing statistik.
4. Mengembangkan dashboard interaktif yang informatif dan mudah digunakan oleh berbagai kalangan stakeholder, dari HR profesional hingga karyawan individual.
5. Melakukan deployment sistem ke lingkungan cloud yang dapat diakses secara publik, sehingga hasil proyek dapat dimanfaatkan secara nyata.

2.4 Akar Penyebab Burnout yang Dianalisis

Berdasarkan kajian literatur dan eksplorasi awal dataset, tim mengidentifikasi lima kelompok akar penyebab burnout yang menjadi fokus analisis dalam proyek ini. Pertama, beban kerja berlebih yang tercermin dari variabel `WorkHoursPerWeek`, di mana karyawan yang bekerja melebihi 50 jam per minggu menunjukkan risiko burnout yang jauh lebih tinggi. Kedua, tingkat stres yang tidak terkelola, yang diukur melalui variabel `StressLevel` pada skala 1 hingga 10. Ketiga, kepuasan kerja yang rendah, yang direpresentasikan oleh variabel `SatisfactionLevel` pada skala 1 hingga 5. Keempat, ketidakseimbangan work-life yang diukur melalui variabel `RemoteRatio` sebagai proksi fleksibilitas kerja. Kelima, faktor demografis dan pengalaman kerja yang mencakup usia, lama pengalaman kerja, gender, dan jabatan.

BAB 3 -DATA UNDERSTANDING

3.1 Sumber Data

Dataset yang digunakan dalam proyek ini adalah Synthetic Employee Burnout Dataset, sebuah dataset sintetis yang dihasilkan menggunakan teknik simulasi berbasis distribusi statistik yang bersumber dari literatur kesehatan mental kerja. Dataset ini dirancang untuk mencerminkan pola nyata burnout di lingkungan kerja sambil menjamin privasi dan keamanan data individu. Dataset tersedia secara publik dan bebas untuk digunakan dalam penelitian dan pendidikan.

Relevansi dataset ini terhadap tujuan proyek sangat tinggi karena mencakup seluruh variabel yang secara teoritis dan empiris berkaitan dengan burnout karyawan, mulai dari variabel demografis (usia, gender), variabel pekerjaan (jabatan, pengalaman, jam kerja), hingga variabel psikologis (tingkat stres, kepuasan kerja). Target variabel (Burnout) tersedia dalam format biner yang jelas, memungkinkan pembangunan model klasifikasi supervised.

3.2 Gambaran Umum Dataset

Atribut	Detail
Nama Dataset	Synthetic Employee Burnout Dataset
Jumlah Baris	2.000 karyawan
Jumlah Kolom (sebelum FE)	10 kolom (termasuk kolom Name)
Jumlah Kolom (setelah FE)	18 kolom
Tipe Data	Numerik (int/float) dan Kategorikal (string)
Missing Values	Tidak ada (0 missing values di semua kolom)
Duplikat	Tidak ada baris duplikat
Format File	CSV (Comma-Separated Values)
Target Variabel	Burnout (binary: 0 = Tidak Burnout, 1 = Burnout)
Distribusi Target	1.871 tidak burnout (93,5%) dan 129 burnout (6,5%)

3.3 Deskripsi Fitur Original

Dataset original terdiri dari 10 kolom sebagaimana dijelaskan dalam tabel berikut. Kolom Name merupakan identifier unik karyawan yang tidak memiliki nilai analitik sehingga dihapus dalam proses data cleaning.

Nama Kolom	Tipe Data	Rentang Nilai	Deskripsi
Name	String	Unik per karyawan	Nama karyawan -identifier, dihapus saat cleaning
Age	Integer	22 – 60 tahun	Usia karyawan dalam tahun
Gender	String	Male / Female	Jenis kelamin karyawan
JobRole	String	5 kategori	Posisi jabatan: Analyst, Engineer, HR, Manager, Sales
Experience	Integer	0 – 39 tahun	Lama pengalaman kerja dalam tahun
WorkHoursPerWeek	Integer	30 – 70 jam	Rata-rata jam kerja per minggu
RemoteRatio	Integer	0 – 100 %	Persentase waktu kerja secara remote
SatisfactionLevel	Float	1,0 – 5,0	Skor kepuasan kerja (1=sangat tidak puas, 5=sangat puas)
StressLevel	Integer	1 – 10	Tingkat stres kerja (1=sangat rendah, 10=sangat tinggi)
Burnout	Integer	0 atau 1	Target: 0 = Tidak Burnout, 1 = Burnout

3.4 Statistik Deskriptif

Analisis statistik deskriptif terhadap fitur-fitur numerik memberikan gambaran awal tentang distribusi dan karakteristik data. Berikut adalah ringkasan statistik kunci untuk fitur-fitur utama:

Fitur	Mean	Std Dev	Min	Q1	Median	Q3	Max
Age	40,69	11,29	22	31	41	50	60
Experience	10,07	9,15	0	3	7	15	39
WorkHoursPerWeek	~50	~11	30	~40	~50	~60	70
RemoteRatio	~50	~29	0	~25	~50	~75	100
SatisfactionLevel	~3,0	~1,1	1,0	~2,0	~3,0	~4,0	5,0
StressLevel	5,43	2,88	1	3	5	8	10
Burnout	0,065	0,246	0	0	0	0	1

3.5 Distribusi Target dan Ketidakseimbangan Kelas

Salah satu karakteristik penting dari dataset ini adalah ketidakseimbangan kelas (class imbalance) pada variabel target Burnout. Dengan hanya 6,5% karyawan yang mengalami burnout (129 dari 2.000), dataset ini tergolong sangat tidak seimbang. Kondisi ini mencerminkan realita dunia nyata di mana burnout, meskipun berdampak besar, merupakan kejadian yang secara statistik relatif jarang terjadi. Namun demikian, ketidakseimbangan kelas ini memerlukan penanganan khusus dalam proses modeling, yakni dengan menggunakan stratified split untuk memastikan proporsi kelas dipertahankan di set pelatihan dan pengujian, serta menggunakan parameter `class_weight='balanced'` pada model untuk mencegah bias prediksi terhadap kelas mayoritas.

3.6 Distribusi Berdasarkan Kategori

Kategori	Distribusi	Burnout Rate
Gender: Male	1.023 karyawan (51,2%)	~6,4%
Gender: Female	977 karyawan (48,8%)	~6,7%
JobRole: Manager	419 karyawan (20,9%)	6,7%

JobRole: Analyst	413 karyawan (20,6%)	4,8%
JobRole: Sales	391 karyawan (19,6%)	7,7%
JobRole: HR	391 karyawan (19,6%)	6,6%
JobRole: Engineer	386 karyawan (19,3%)	6,5%

BAB 4 - DATA PREPARATION

4.1 Proses Gathering Data

Dataset diperoleh dalam format file CSV dengan nama `synthetic_employee_burnout.csv` dan dimuat menggunakan library `pandas` dengan fungsi `pd.read_csv()`. Proses loading dilakukan dengan memverifikasi integritas file dan memastikan seluruh 2.000 baris dan 10 kolom berhasil dimuat dengan benar. Dataset ini tersedia secara lokal sebagai bagian dari repositori proyek.

4.2 Assessing Data -Penilaian Kualitas Data

Tahap penilaian kualitas data dilakukan secara sistematis dengan memeriksa empat aspek kualitas utama:

4.2.1 Pemeriksaan Missing Values

Pemeriksaan dilakukan menggunakan fungsi `df.isnull().sum()` terhadap seluruh kolom. Hasilnya menunjukkan bahwa tidak ada satu pun nilai yang hilang (`missing`) di seluruh kolom dataset. Total missing values adalah 0, yang berarti dataset sudah sangat bersih dari sisi kelengkapan data. Kondisi ini merupakan keunggulan dari dataset sintetis yang dihasilkan secara terkontrol.

4.2.2 Pemeriksaan Duplikasi

Pemeriksaan dilakukan menggunakan fungsi `df.duplicated().sum()`. Hasilnya menunjukkan tidak ada baris duplikat dalam dataset (0 duplikat). Setiap baris merepresentasikan satu karyawan yang unik, sehingga tidak diperlukan proses deduplication.

4.2.3 Pemeriksaan Validitas Range Nilai

Setiap kolom numerik divalidasi terhadap rentang nilai yang secara domain logic seharusnya valid. Hasil validasi menunjukkan seluruh nilai berada dalam rentang yang valid sesuai dengan definisi domain masing-masing variabel, sebagaimana ditunjukkan pada tabel berikut:

Kolom	Rentang Valid	Status Validasi
Age	[22, 60] tahun	VALID -tidak ada nilai di luar rentang
Experience	[0, 40] tahun	VALID -tidak ada nilai di luar rentang
WorkHoursPerWeek	[30, 80] jam	VALID -tidak ada nilai di luar rentang
RemoteRatio	[0, 100] %	VALID -tidak ada nilai di luar rentang
SatisfactionLevel	[1,0, 5,0]	VALID -tidak ada nilai di luar rentang
StressLevel	[1, 10]	VALID -tidak ada nilai di luar rentang
Burnout	[0, 1]	VALID -hanya nilai 0 atau 1

4.3 Cleaning Data

Meskipun dataset sudah dalam kondisi yang sangat bersih, proses data cleaning tetap dilakukan secara sistematis untuk memastikan kualitas optimal dan kesiapan data untuk analisis dan pemodelan. Langkah-langkah cleaning yang diterapkan adalah sebagai berikut.

4.3.1 Penghapusan Kolom Name

Kolom Name dihapus dari dataset karena merupakan identifier unik yang tidak memiliki nilai informatif untuk analisis atau pemodelan. Mempertahankan kolom ini dapat menyebabkan data leakage jika model mencoba belajar dari nama karyawan. Setelah penghapusan, dataset memiliki 9 kolom aktif.

4.3.2 Pembuatan Kolom RiskLevel

Sebagai bagian dari proses enrichment data, kolom RiskLevel ditambahkan sebagai variabel target multi-kelas yang dihasilkan melalui aturan berbasis skor (rule-based scoring). Setiap karyawan diberikan skor risiko berdasarkan tiga faktor utama: jam kerja per minggu, tingkat stres, dan tingkat kepuasan kerja. Skor dari ketiga faktor dijumlahkan dan dikategorikan menjadi tiga level risiko: Rendah (skor 0-1), Sedang (skor 2-3), dan Tinggi (skor ≥ 4). Hasilnya, dari 2.000 karyawan, 308 (15,4%) dikategorikan Risiko Rendah, 952 (47,6%) Risiko Sedang, dan 740 (37,0%) Risiko Tinggi.

4.3.3 Penanganan Imputasi

Meskipun tidak ditemukan missing values pada dataset ini, pipeline imputasi tetap disiapkan sebagai langkah antisipasi untuk data nyata di masa depan. Strategi yang ditetapkan adalah imputasi dengan nilai median untuk kolom numerik (lebih robust terhadap outlier dibandingkan mean) dan imputasi dengan nilai modus untuk kolom kategorikal.

4.4 Dataset Akhir Setelah Cleaning

Setelah seluruh proses data wrangling selesai, dataset bersih (`df_clean.csv`) yang dihasilkan memiliki 2.000 baris dan 10 kolom aktif (9 kolom original minus Name, ditambah kolom RiskLevel hasil rekayasa). Dataset ini kemudian digunakan sebagai dasar untuk seluruh proses EDA, Feature Engineering, dan Modeling.

BAB 5 - EXPLORATORY DATA ANALYSIS (EDA)

5.1 Tujuan dan Pendekatan EDA

Exploratory Data Analysis (EDA) merupakan tahap kritis dalam pipeline Data Science yang bertujuan untuk memahami struktur, distribusi, pola, dan hubungan antar variabel dalam dataset sebelum tahap pemodelan. Pendekatan EDA dalam proyek ini mencakup empat dimensi analisis: analisis distribusi univariat, analisis komparatif bivariat (burnout vs tidak burnout), analisis korelasi multivariat, dan deteksi outlier.

5.2 Analisis Distribusi Fitur

Analisis distribusi dilakukan menggunakan kombinasi histogram dan Kernel Density Estimate (KDE) yang divisualisasikan secara terpisah untuk kelompok Burnout=0 dan Burnout=1. Pemilihan histogram + KDE didasarkan pada kemampuannya untuk secara simultan menampilkan frekuensi nilai (histogram) dan estimasi distribusi probabilitas kontinu (KDE), sehingga perbedaan pola distribusi antar kelompok dapat terlihat dengan jelas. Analisis distribusi menghasilkan temuan-temuan berikut.

5.2.1 Distribusi WorkHoursPerWeek

Distribusi jam kerja per minggu memperlihatkan pola yang sangat informatif terkait burnout. Karyawan yang mengalami burnout secara konsisten menunjukkan konsentrasi nilai yang lebih tinggi pada rentang jam kerja 50-70 jam per minggu, sementara karyawan yang tidak burnout lebih terdistribusi merata di rentang 30-60 jam. Rata-rata jam kerja karyawan burnout secara signifikan lebih tinggi dibandingkan karyawan tidak burnout, mengkonfirmasi bahwa WorkHoursPerWeek merupakan prediktor yang kuat.

5.2.2 Distribusi StressLevel

Tingkat stres menunjukkan perbedaan distribusi yang paling mencolok antara dua kelompok. Karyawan yang mengalami burnout hampir seluruhnya terkonsentrasi pada StressLevel 7-10 (kategori tinggi), sementara tidak ada satu pun karyawan dengan StressLevel rendah (< 7) yang mengalami burnout. Hal ini mengindikasikan bahwa StressLevel berfungsi sebagai kondisi yang hampir perlu (necessary condition) untuk terjadinya burnout dalam dataset ini.

5.2.3 Distribusi SatisfactionLevel

Karyawan yang mengalami burnout secara umum memiliki SatisfactionLevel yang lebih rendah, dengan distribusi yang lebih condong ke nilai 1-3 dibandingkan karyawan tidak burnout yang distribusinya lebih luas dan merata di seluruh rentang 1-5. Korelasi negatif ini mengkonfirmasi intuisi bahwa kepuasan kerja yang rendah merupakan faktor risiko burnout yang signifikan.

5.2.4 Distribusi Age dan Experience

Distribusi usia dan pengalaman kerja tidak menunjukkan perbedaan yang signifikan antara karyawan burnout dan tidak burnout. Kedua fitur ini memiliki distribusi yang hampir identik untuk kedua kelompok, mengindikasikan bahwa usia dan pengalaman tidak secara langsung menjadi prediktor kuat burnout dalam dataset ini.

5.2.5 Distribusi RemoteRatio

Rasio kerja remote tidak menunjukkan pola yang kuat dalam membedakan kelompok burnout dan tidak burnout. Distribusi kedua kelompok relatif serupa, mengindikasikan bahwa meskipun RemoteRatio secara teoritis berkaitan dengan work-life balance, dampaknya terhadap burnout dalam dataset ini bersifat tidak langsung.

5.3 Analisis Korelasi

Analisis korelasi dilakukan menggunakan Pearson Correlation Coefficient terhadap seluruh pasang fitur numerik, divisualisasikan dalam bentuk heatmap korelasi. Heatmap dengan colormap 'coolwarm' dipilih karena memungkinkan identifikasi korelasi positif (merah) dan negatif (biru) secara intuitif dan sekaligus untuk seluruh pasang fitur.

Fitur	Korelasi dengan Burnout	Arah	Kekuatan
StressLevel	+0,3210	Positif	Sedang-Kuat
SatisfactionLevel	-0,2326	Negatif	Sedang
WorkHoursPerWeek	+0,2260	Positif	Sedang
RemoteRatio	+0,0109	Positif	Sangat Lemah

Experience	-0,0153	Negatif	Sangat Lemah
Age	+0,0040	Positif	Sangat Lemah

StressLevel adalah prediktor dengan korelasi terkuat terhadap Burnout ($r = +0,321$), diikuti oleh SatisfactionLevel ($r = -0,233$) dan WorkHoursPerWeek ($r = +0,226$). Sebaliknya, usia, pengalaman, dan rasio remote hampir tidak memiliki korelasi linear yang berarti dengan burnout. Temuan ini konsisten dengan literatur psikologi industri yang menempatkan stres kerja dan kepuasan kerja sebagai prediktor utama burnout.

5.4 Deteksi Outlier

Deteksi outlier dilakukan menggunakan metode Interquartile Range (IQR), di mana sebuah nilai dikategorikan sebagai outlier jika berada di luar batas $[Q1 - 1,5 \times IQR, Q3 + 1,5 \times IQR]$. Metode IQR dipilih karena robust terhadap distribusi non-normal dan umum digunakan dalam analisis data eksplorasi. Hasil deteksi menunjukkan bahwa tidak ada outlier yang signifikan pada fitur-fitur utama WorkHoursPerWeek, StressLevel, dan SatisfactionLevel, mengkonfirmasi bahwa dataset sintesis ini dihasilkan dengan kontrol distribusi yang baik.

5.5 Analisis Komparatif: Burnout vs Tidak Burnout

Perbandingan nilai rata-rata fitur antara kelompok burnout dan tidak burnout memberikan insight yang sangat berharga. Karyawan yang mengalami burnout memiliki rata-rata StressLevel yang jauh lebih tinggi, WorkHoursPerWeek yang lebih besar, dan SatisfactionLevel yang lebih rendah dibandingkan karyawan yang tidak mengalami burnout. Visualisasi boxplot memperkuat temuan ini dengan menunjukkan bahwa distribusi ketiga fitur tersebut jelas terpisah antara dua kelompok, dengan sedikit tumpang tindih hanya pada nilai-nilai tertentu.

5.6 Analisis Skewness dan Kurtosis

Analisis skewness dan kurtosis memberikan informasi tentang bentuk distribusi data. WorkHoursPerWeek menunjukkan distribusi yang relatif simetris (skewness mendekati 0), sementara StressLevel sedikit left-skewed yang mengindikasikan lebih banyak karyawan dengan tingkat stres menengah ke tinggi. SatisfactionLevel menunjukkan distribusi yang cukup simetris. Nilai kurtosis yang mendekati 0 untuk sebagian besar fitur mengindikasikan

distribusi yang mendekati normal (mesokurtic), yang merupakan kondisi yang ideal untuk sebagian besar algoritma Machine Learning.

BAB 6 -FEATURE ENGINEERING

6.1 Pendekatan dan Filosofi

Feature Engineering merupakan seni dan ilmu menciptakan representasi data yang lebih informatif untuk model Machine Learning. Dalam proyek ini, feature engineering dilakukan berdasarkan dua pendekatan: domain knowledge (pemahaman mendalam tentang psikologi burnout dan manajemen SDM) dan temuan dari tahap EDA. Setiap fitur rekayasa yang diciptakan memiliki justifikasi konseptual yang kuat, bukan sekadar transformasi matematis tanpa makna.

6.2 Encoding Variabel Kategorikal

Dua kolom kategorikal dalam dataset, yakni Gender dan JobRole, perlu dikonversi menjadi representasi numerik agar dapat diproses oleh algoritma Machine Learning. Metode Label Encoding dipilih (bukan One-Hot Encoding) dengan pertimbangan bahwa model tree-based seperti Random Forest dan Gradient Boosting, yang menjadi kandidat utama dalam proyek ini, dapat menangani label encoding dengan baik tanpa memerlukan transformasi one-hot yang akan menambah dimensi fitur secara tidak perlu. Gender diencode menjadi: Female = 0, Male = 1. JobRole diencode menjadi nilai integer 0 hingga 4 berdasarkan urutan alfabetis: Analyst = 0, Engineer = 1, HR = 2, Manager = 3, Sales = 4.

6.3 Fitur Rekayasa yang Diciptakan

Enam fitur baru diciptakan melalui proses feature engineering sebagaimana dijelaskan di bawah ini:

6.3.1 StressWorkRatio

Definisi: $\text{StressLevel} / (\text{WorkHoursPerWeek} + 1)$. Fitur ini mengukur intensitas stres per unit waktu kerja, menangkap perbedaan antara karyawan yang stres tinggi dalam jam kerja sedikit versus banyak. Pembagi $(\text{WorkHoursPerWeek} + 1)$ digunakan untuk menghindari pembagian dengan nol. Fitur ini relevan karena dua karyawan dengan StressLevel yang sama namun jam kerja berbeda akan memiliki profil risiko yang berbeda.

6.3.2 WorkLifeScore

Definisi: $\text{SatisfactionLevel} \times (1 - \text{RemoteRatio}/100)$. Fitur ini mengukur skor keseimbangan kerja-hidup yang mempertimbangkan kepuasan kerja dan fleksibilitas bekerja dari rumah. Semakin rendah kepuasan kerja dan semakin sedikit fleksibilitas remote, semakin rendah WorkLifeScore, yang mengindikasikan risiko burnout yang lebih tinggi.

6.3.3 HighRiskFlag

Definisi: 1 jika $\text{StressLevel} \geq 7$ DAN $\text{WorkHoursPerWeek} \geq 50$, selain itu 0. Fitur biner ini menandai karyawan yang berada dalam kondisi double high-risk, yaitu stres tinggi sekaligus beban kerja berat. Berdasarkan analisis EDA, kombinasi ini terbukti memiliki burnout rate yang jauh lebih tinggi. Dalam dataset, sebanyak 24,6% karyawan memiliki $\text{HighRiskFlag} = 1$ dengan burnout rate yang secara signifikan lebih tinggi. Fitur ini terbukti menjadi yang paling prediktif dalam model Decision Tree (feature importance = 0,7448).

6.3.4 SeniorEmployee

Definisi: 1 jika $\text{Experience} \geq 10$ tahun, selain itu 0. Fitur ini mengkategorikan karyawan berdasarkan senioritas. Secara teoritis, karyawan senior mungkin memiliki mekanisme coping yang lebih baik terhadap stres, namun di sisi lain juga mungkin menghadapi ekspektasi dan tanggung jawab yang lebih besar. Fitur ini memungkinkan model untuk menangkap efek non-linear dari pengalaman terhadap risiko burnout.

6.3.5 StressCategory

Definisi: 0 jika $\text{StressLevel} \leq 3$ (Rendah), 1 jika $\text{StressLevel} 4-6$ (Sedang), 2 jika $\text{StressLevel} \geq 7$ (Tinggi). Dengan mengkategorikan StressLevel menjadi tiga kelas ordinal, fitur ini memungkinkan model untuk menangkap efek threshold (batas) dari stres, di mana peningkatan stres dari level 6 ke 7 mungkin memiliki dampak yang jauh lebih besar dibandingkan peningkatan dari level 3 ke 4.

6.3.6 SatisfactionInverse

Definisi: $5,0 - \text{SatisfactionLevel}$. Fitur ini mentransformasi kepuasan kerja menjadi skor ketidakpuasan, sehingga berkorelasi positif dengan burnout (semakin tinggi ketidakpuasan, semakin tinggi burnout). Transformasi ini membantu model dalam menginterpretasikan fitur kepuasan kerja secara lebih intuitif dalam konteks prediksi burnout.

6.4 Ringkasan Feature List untuk Model

Total 14 fitur digunakan sebagai input untuk model Machine Learning, terdiri dari 6 fitur original (setelah encoding) dan 6 fitur rekayasa baru:

#	Nama Fitur	Jenis	Peran
1	Age	Original	Demografis
2	Experience	Original	Riwayat Kerja
3	WorkHoursPerWeek	Original	Beban Kerja
4	RemoteRatio	Original	Fleksibilitas Kerja
5	SatisfactionLevel	Original	Kepuasan Kerja
6	StressLevel	Original	Kesehatan Mental
7	Gender_enc	Encoded	Demografis
8	JobRole_enc	Encoded	Jabatan
9	StressWorkRatio	Rekayasa	Interaksi Stres-Waktu
10	WorkLifeScore	Rekayasa	Work-Life Balance
11	HighRiskFlag	Rekayasa	Flag Risiko Tinggi
12	SeniorEmployee	Rekayasa	Senioritas
13	StressCategory	Rekayasa	Kategorisasi Stres
14	SatisfactionInverse	Rekayasa	Ketidakpuasan

6.5 Scaling Fitur

StandardScaler dari scikit-learn diterapkan untuk menormalisasi seluruh fitur sehingga setiap fitur memiliki mean = 0 dan standar deviasi = 1. Meskipun model tree-based tidak secara fundamental memerlukan scaling (karena hanya membuat keputusan berdasarkan perbandingan threshold, bukan jarak), scaling tetap diterapkan untuk konsistensi pipeline dan untuk mendukung perbandingan yang adil dengan model berbasis jarak seperti Logistic Regression.

BAB 7 - MODEL DEVELOPMENT

7.1 Strategi Pemodelan

Strategi pemodelan dalam proyek ini mengikuti pendekatan perbandingan multi-model (multi-model comparison), di mana empat algoritma berbeda dievaluasi secara sistematis menggunakan metrik yang sama untuk mengidentifikasi model terbaik. Pendekatan ini dipilih karena tidak ada satu algoritma pun yang secara universal optimal untuk semua jenis dataset, sehingga evaluasi empiris diperlukan.

7.2 Pembagian Data

Dataset dibagi menjadi training set (80%) dan test set (20%) menggunakan Stratified K-Fold Split dengan `random_state = 42`. Stratified split digunakan untuk memastikan proporsi kelas burnout (6,5%) dipertahankan secara konsisten di kedua set, mengingat ketidakseimbangan kelas yang ada. Pembagian menghasilkan 1.600 data latih dan 400 data uji.

7.3 Model yang Dievaluasi

7.3.1 Logistic Regression

Logistic Regression merupakan model linear yang memodelkan probabilitas kelas menggunakan fungsi logistik (sigmoid). Model ini dipilih sebagai baseline karena sifatnya yang interpretatif dan komputasi yang efisien. Konfigurasi yang digunakan: `max_iter = 1000`, `random_state = 42`, `class_weight = 'balanced'`. Parameter `class_weight = 'balanced'` memungkinkan model untuk secara otomatis menyesuaikan bobot kelas berdasarkan frekuensinya, sehingga kelas minoritas (burnout) mendapatkan perhatian yang proporsional dalam proses optimasi.

7.3.2 Decision Tree

Decision Tree membangun model prediktif dengan membuat serangkaian keputusan hierarkis berdasarkan nilai fitur. Setiap node dalam pohon keputusan merepresentasikan kondisi terhadap satu fitur, dan setiap cabang merepresentasikan hasil dari kondisi tersebut. Konfigurasi yang digunakan: `max_depth = 5`, `random_state = 42`, `class_weight = 'balanced'`.

Batasan `max_depth = 5` diterapkan untuk mencegah overfitting dengan membatasi kompleksitas pohon keputusan.

7.3.3 Random Forest

Random Forest adalah metode ensemble yang membangun sejumlah besar Decision Tree secara independen menggunakan teknik bagging (Bootstrap Aggregating) dan random feature selection. Prediksi akhir dihasilkan melalui voting mayoritas dari seluruh pohon. Konfigurasi yang digunakan: `n_estimators = 100`, `random_state = 42`, `class_weight = 'balanced'`, `n_jobs = -1` (menggunakan seluruh core CPU yang tersedia). Random Forest dikenal sangat robust terhadap overfitting dan noise dalam data.

7.3.4 Gradient Boosting

Gradient Boosting adalah metode ensemble yang membangun pohon keputusan secara sekuensial, di mana setiap pohon baru berfokus untuk memperbaiki kesalahan yang dibuat oleh pohon-pohon sebelumnya. Proses ini dilakukan dengan cara mengoptimalkan fungsi loss menggunakan gradient descent. Konfigurasi yang digunakan: `n_estimators = 100`, `random_state = 42`. Gradient Boosting umumnya menghasilkan performa yang lebih tinggi dibandingkan Random Forest pada dataset terstruktur, namun lebih sensitif terhadap hyperparameter.

7.4 Validasi Silang (Cross-Validation)

Untuk mendapatkan estimasi performa yang lebih stabil dan tidak terbias terhadap pembagian data tertentu, Stratified K-Fold Cross Validation dengan 5 fold digunakan. Metrik yang dioptimalkan dalam cross-validation adalah F1-Score, yang dipilih karena lebih informatif dibandingkan accuracy pada dataset imbalanced. Dalam setiap fold, model dilatih pada 4 subset data dan divalidasi pada 1 subset data yang tersisa, sehingga setiap observasi digunakan sebagai data validasi tepat satu kali.

BAB 8 -MODEL EVALUATION

8.1 Hasil Evaluasi Komprehensif

Seluruh empat model dievaluasi menggunakan lima metrik utama pada test set, serta F1-Score mean dan standar deviasi dari cross-validation 5-fold. Hasil evaluasi lengkap disajikan dalam tabel berikut:

Model	Accuracy	F1-Score	Precision	Recall	AUC-ROC	CV F1 Mean	CV F1 Std
Logistic Regression	0,9525	0,7324	0,5778	1,0000	0,9937	0,7482	±0,0204
Decision Tree	1,0000	1,0000	1,0000	1,0000	1,0000	0,9961	±0,0078
Random Forest	1,0000	1,0000	1,0000	1,0000	1,0000	0,9961	±0,0078
Gradient Boosting	1,0000	1,0000	1,0000	1,0000	1,0000	0,9961	±0,0078

8.2 Analisis Hasil per Model

8.2.1 Logistic Regression

Logistic Regression mencapai Accuracy sebesar 95,25% dan AUC-ROC yang sangat tinggi (0,9937), mengindikasikan kemampuan diskriminasi yang luar biasa antara kelas burnout dan tidak burnout. Namun, Precision-nya yang relatif rendah (0,5778) mengindikasikan bahwa model ini cenderung menghasilkan false positives yang cukup tinggi -mengklasifikasikan banyak karyawan sebagai burnout padahal sebenarnya tidak. Recall yang sempurna (1,000) mengindikasikan bahwa model tidak melewatkan satu pun kasus burnout yang sebenarnya, yang merupakan karakteristik penting dalam konteks kesehatan kerja di mana false negative (melewatkan kasus burnout) lebih berbahaya daripada false positive.

8.2.2 Decision Tree, Random Forest, dan Gradient Boosting

Ketiga model tree-based mencapai performa sempurna pada test set (seluruh metrik = 1,000) dan hampir sempurna pada cross-validation (CV F1 = $0,9961 \pm 0,0078$). Performa sempurna pada test set ini konsisten dengan pola yang terlihat dalam EDA, di mana

perbedaan antara kelas burnout dan tidak burnout sangat jelas terutama pada fitur HighRiskFlag. Model Decision Tree mampu menemukan aturan sederhana berbasis HighRiskFlag dan SatisfactionInverse yang hampir sempurna dalam memisahkan kedua kelas.

8.2.3 Catatan tentang Performa Sempurna

Performa sempurna (AUC-ROC = 1,000) pada dataset ini perlu diinterpretasikan dengan hati-hati. Dari analisis feature importance, HighRiskFlag memiliki importance score 0,7448 - hampir tiga perempat dari seluruh kekuatan prediktif model berasal dari satu fitur ini. Mengingat bahwa HighRiskFlag merupakan fitur rekayasa yang didefinisikan berdasarkan aturan ($\text{StressLevel} \geq 7$ AND $\text{WorkHoursPerWeek} \geq 50$), dan mengingat bahwa burnout dalam dataset ini hanya terjadi pada karyawan dengan kombinasi tersebut, maka model pada dasarnya mempelajari kembali aturan yang sudah tertanam dalam feature engineering. Ini merupakan karakteristik yang khas dari dataset sintetis di mana pola dapat didefinisikan secara deterministik, berbeda dari data nyata yang lebih kompleks dan penuh noise.

8.3 Feature Importance Analysis

Analisis feature importance dari model Decision Tree (yang juga merepresentasikan model terbaik) menghasilkan ranking berikut:

Peringkat	Fitur	Importance Score	Interpretasi
1	HighRiskFlag	0,7448	Faktor paling dominan -kombinasi stres tinggi + jam panjang
2	SatisfactionInverse	0,1981	Ketidakpuasan kerja -prediktor kuat kedua
3	StressLevel	0,0452	Tingkat stres raw
4	WorkHoursPerWeek	0,0120	Jam kerja mentah
5-14	Fitur Lainnya	0,0000	Tidak berkontribusi pada model ini

Temuan ini menegaskan bahwa kombinasi stres tinggi dengan jam kerja panjang (HighRiskFlag) merupakan indikator burnout yang paling kuat, diikuti oleh ketidakpuasan

kerja. Kedua faktor ini harus menjadi prioritas utama dalam program pencegahan burnout di organisasi.

8.4 Model yang Dipilih

Model Decision Tree dipilih sebagai model final yang disimpan dalam artifacts (model_artifacts.pkl) berdasarkan AUC-ROC tertinggi. Artifacts yang disimpan mencakup model terbaik, StandardScaler yang sudah fitted, LabelEncoder untuk Gender dan JobRole, daftar fitur, dan tabel hasil evaluasi seluruh model. Artifacts ini dapat langsung digunakan untuk inference oleh tim AI Engineer melalui FastAPI atau sistem lain.

BAB 9 - A/B TESTING

9.1 Tujuan dan Kerangka A/B Testing

A/B Testing dalam konteks proyek ini digunakan untuk memvalidasi secara statistik apakah perbedaan yang diamati -baik antara performa model maupun antara kelompok karyawan -benar-benar bermakna secara statistik atau hanya terjadi secara kebetulan akibat variabilitas sampling. Pendekatan ini mengintegrasikan metode statistik inferensial ke dalam pipeline Data Science untuk memastikan keputusan yang dibuat berdasarkan bukti yang kuat.

9.2 Metodologi Statistik

Metode statistik yang digunakan adalah Two-Sample Independent t-test (uji-t dua sampel independen). Pemilihan metode ini didasarkan pada beberapa pertimbangan: sampel yang dibandingkan bersifat independen (tidak ada hubungan antara satu sampel dengan yang lain), ukuran sampel cukup besar untuk mengasumsikan distribusi normal berdasarkan Central Limit Theorem, dan tujuannya adalah membandingkan nilai rata-rata dua kelompok.

Tingkat signifikansi yang ditetapkan adalah $\alpha = 0,05$, yang merupakan standar yang umum digunakan dalam penelitian ilmu sosial dan bisnis. Sebuah perbedaan dinyatakan signifikan secara statistik jika nilai p-value yang dihasilkan lebih kecil dari $\alpha = 0,05$, yang berarti probabilitas mengamati perbedaan sebesar itu secara kebetulan (jika H_0 benar) adalah kurang dari 5 persen.

9.3 A/B Test 1 -Logistic Regression vs Random Forest

Formulasi Hipotesis

H_0 (Hipotesis Null): Tidak ada perbedaan yang signifikan antara F1-Score Logistic Regression dan Random Forest ($\mu_{LR} = \mu_{RF}$). H_1 (Hipotesis Alternatif): Terdapat perbedaan yang signifikan, dengan Random Forest memiliki F1-Score yang lebih tinggi ($\mu_{RF} > \mu_{LR}$).

Data yang Digunakan

Skor F1 dari 5-fold cross-validation untuk Logistic Regression: [nilai fold 1-5]. Skor F1 dari 5-fold cross-validation untuk Random Forest: [nilai fold 1-5]. Mean LR = 0,7482, Mean RF = 0,9961.

Statistik	Nilai
Mean F1 -Logistic Regression	0,7482
Mean F1 -Random Forest	0,9961
Metode Uji	Independent t-test (dua sisi)
Tingkat Signifikansi (α)	0,05
Keputusan	TOLAK H0 -perbedaan signifikan ($p \ll 0,05$)
Pemenang	Random Forest

Interpretasi Bisnis: Perbedaan F1-Score yang signifikan antara Logistic Regression dan Random Forest mengkonfirmasi bahwa model non-linear berbasis ensemble memberikan prediksi yang secara substansial lebih akurat untuk masalah burnout ini. Untuk deployment produksi yang memerlukan akurasi tertinggi, penggunaan model tree-based direkomendasikan.

9.4 A/B Test 2 -Random Forest vs Gradient Boosting

H0: Tidak ada perbedaan F1-Score antara Random Forest dan Gradient Boosting ($\mu_{RF} = \mu_{GB}$). H1: Terdapat perbedaan signifikan antara kedua model.

Statistik	Nilai
Mean F1 -Random Forest	0,9961
Mean F1 -Gradient Boosting	0,9961
Std Dev RF	0,0078
Std Dev GB	0,0078
Keputusan	GAGAL TOLAK H0 -tidak ada perbedaan signifikan

Interpretasi Bisnis: Random Forest dan Gradient Boosting memiliki performa yang setara secara statistik pada dataset ini. Dalam kondisi performa yang setara, Random Forest lebih direkomendasikan untuk deployment karena lebih cepat dalam training, lebih parallel,

dan umumnya lebih robust terhadap overfitting. Gradient Boosting menjadi alternatif yang kuat ketika diperlukan fine-tuning yang lebih agresif.

9.5 A/B Test 3 -Burnout Rate: Jam Kerja Tinggi vs Rendah

Eksperimen A/B Testing ketiga dan paling penting dari perspektif bisnis adalah membandingkan burnout rate antara dua kelompok karyawan berdasarkan jam kerja mereka: kelompok dengan jam kerja tinggi (≥ 50 jam per minggu) versus kelompok dengan jam kerja rendah (< 40 jam per minggu).

H0: Tidak ada perbedaan yang signifikan antara burnout rate karyawan dengan jam kerja tinggi dan rendah. H1: Karyawan dengan jam kerja tinggi memiliki burnout rate yang secara statistik lebih tinggi dibandingkan karyawan dengan jam kerja rendah.

Statistik	Nilai
Kelompok A: < 40 jam/minggu	n = 504 karyawan, burnout rate = 0,00%
Kelompok B: ≥ 50 jam/minggu	n = 983 karyawan, burnout rate = 13,12%
Perbedaan Burnout Rate	+13,12 percentage point
t-statistic	8,7194
p-value	$< 0,00000001$ (sangat kecil)
Tingkat Signifikansi (α)	0,05
Keputusan	TOLAK H0 -perbedaan sangat signifikan ($p \ll 0,001$)

Interpretasi Bisnis: Temuan ini memiliki implikasi praktis yang sangat penting bagi manajemen SDM. Tidak ada satu pun karyawan yang bekerja kurang dari 40 jam per minggu yang mengalami burnout, sementara 13,12% karyawan yang bekerja 50 jam atau lebih mengalami burnout. Perbedaan yang sangat signifikan secara statistik ($p < 0,001$) ini memberikan dasar ilmiah yang kuat untuk implementasi kebijakan pembatasan jam kerja. Rekomendasi konkret: organisasi sebaiknya menetapkan batas maksimal jam kerja 48-50 jam per minggu dan memantau secara aktif karyawan yang secara konsisten melebihi batas ini sebagai kelompok prioritas untuk intervensi wellness.

BAB 10 - DASHBOARD DEVELOPMENT

10.1 Tujuan dan Arsitektur Dashboard

Dashboard interaktif dikembangkan menggunakan framework Streamlit (versi $\geq 1.28.0$), sebuah framework Python open-source yang memungkinkan pembuatan aplikasi web data science secara cepat tanpa memerlukan keahlian frontend development. Dashboard ini dirancang sebagai antarmuka utama yang menjembatani hasil analisis teknis dengan kebutuhan pengguna dari berbagai latar belakang -dari data scientist, HR profesional, hingga karyawan individual.

Arsitektur dashboard bersifat single-file, di mana seluruh kode dashboard terdapat dalam satu file Python (`dashboard_burnout.py`). File ini memuat model artifacts dari `model_artifacts.pkl` dan dataset bersih dari `df_clean.csv` secara dinamis menggunakan decorator `@st.cache_resource` dan `@st.cache_data` untuk mengoptimalkan performa dengan menyimpan data dalam cache memori.

10.2 Halaman Dashboard

Dashboard terdiri dari sembilan halaman navigasi yang dapat diakses melalui dropdown di sidebar:

Halaman 1 -Overview & Problem Statement

Halaman utama yang menyajikan ringkasan eksekutif proyek, pernyataan masalah, solusi yang dikembangkan, dan KPI cards yang menampilkan metrik utama dataset secara real-time (total karyawan, jumlah karyawan burnout, rata-rata stres, rata-rata jam kerja, rata-rata kepuasan). Halaman ini juga menampilkan preview dataset dan Data Dictionary interaktif.

Halaman 2 -Exploratory Data Analysis

Halaman EDA yang menyajikan lima tab interaktif: (1) Distribusi Fitur dengan dropdown pilihan fitur dan perbandingan statistik burnout vs tidak burnout; (2) Heatmap Korelasi lengkap beserta interpretasi korelasi per fitur terhadap target; (3) Burnout Rate per Kategori dengan pilihan JobRole, Gender, atau RiskLevel; (4) Boxplot Perbandingan dengan dropdown pilihan fitur; (5) Statistik Deskriptif lengkap beserta analisis skewness dan kurtosis.

Halaman 3 -Explanatory Analysis (Business Questions)

Halaman ini menjawab ketujuh business questions yang telah didefinisikan melalui tujuh tab interaktif. Setiap tab menyajikan visualisasi yang relevan beserta interpretasi bisnis dan insight yang dapat langsung digunakan oleh pengambil keputusan.

Halaman 4 -Kuesioner Kepuasan Kerja

Halaman kuesioner interaktif yang memungkinkan karyawan mengevaluasi tingkat kepuasan kerja mereka melalui empat pertanyaan berskala 1-5 yang mencakup kenyamanan lingkungan kerja, kepuasan workload, work-life balance, dan apresiasi perusahaan. Skor rata-rata dihitung secara otomatis dan dikategorikan menjadi tiga level beserta pesan umpan balik yang sesuai.

Halaman 5 -Kuesioner Tingkat Stres

Halaman serupa yang mengukur tingkat stres karyawan melalui empat pertanyaan terkait kelelahan, kesulitan fokus, tekanan deadline, dan habisnya energi. Hasil dikategorikan ke dalam tingkat rendah, sedang, atau tinggi.

Halaman 6 -Prediksi Individu

Ini merupakan halaman paling powerful dalam dashboard. Pengguna dapat memasukkan profil lengkap karyawan (usia, gender, jabatan, pengalaman, jam kerja, rasio remote, kepuasan, dan stres) dan mendapatkan prediksi risiko burnout secara real-time. Dashboard menghitung hybrid burnout probability score dengan mempertimbangkan output model ML dan aturan berbasis scoring, menampilkan level risiko dengan warna yang intuitif (hijau/kuning/merah), progress bar probabilitas, dan rekomendasi wellness yang dipersonalisasi berdasarkan profil individu.

Halaman 7 -Reminder Burnout Check

Fitur yang memungkinkan karyawan atau HR mendaftarkan pengingat berkala untuk melakukan burnout self-check. Pengguna dapat mengatur interval (3, 7, 14, atau 30 hari) dan memasukkan email untuk notifikasi.

Halaman 8 -Performa Model

Halaman teknis yang menampilkan perbandingan performa seluruh model dalam tabel dengan highlight sel tertinggi, visualisasi metrik per model dalam grouped bar chart interaktif,

feature importance chart dengan kode warna berdasarkan tingkat kepentingan, serta interpretasi komprehensif tentang implikasi hasil evaluasi.

Halaman 9 -A/B Testing

Halaman yang merepresentasikan hasil A/B Testing secara interaktif dalam tiga tab: perbandingan Logistic Regression vs Random Forest, perbandingan Random Forest vs Gradient Boosting, dan analisis burnout rate berdasarkan jam kerja dengan slider interaktif untuk mengatur threshold jam kerja.

10.3 Desain dan UI/UX

Dashboard menggunakan custom CSS yang didefinisikan langsung dalam kode untuk menciptakan tampilan yang profesional dan modern. Elemen desain utama mencakup: header gradient berwarna ungu-biru untuk kesan profesional, metric cards dengan box shadow untuk KPI, badge risiko berwarna (merah/kuning/hijau) untuk status risiko, dan sidebar berwarna gelap (1a1a2e) untuk kontras yang baik. Tata letak menggunakan multi-column layout (st.columns) untuk memaksimalkan penggunaan ruang layar dan meningkatkan keterbacaan.

BAB 11 - DEPLOYMENT

11.1 Arsitektur Deployment

Deployment proyek ini menggunakan Streamlit Community Cloud (sebelumnya dikenal sebagai Streamlit Sharing), sebuah platform cloud gratis yang disediakan oleh Streamlit untuk hosting aplikasi Streamlit secara publik. Arsitektur deployment bersifat serverless di mana Streamlit Cloud secara otomatis mengelola infrastruktur komputasi, sehingga tim tidak perlu mengonfigurasi server, container, atau environment secara manual.

11.2 Prasyarat Deployment

Untuk melakukan deployment ke Streamlit Cloud, diperlukan empat file inti dalam repositori GitHub yang sama: `dashboard_burnout.py` sebagai file aplikasi utama, `model_artifacts.pkl` sebagai file model ML dan preprocessing artifacts, `df_clean.csv` sebagai file dataset bersih, dan `requirements.txt` yang mendefinisikan seluruh dependensi Python yang diperlukan.

11.3 File Requirements.txt

File `requirements.txt` mendefinisikan seluruh library Python beserta versi minimumnya yang diperlukan untuk menjalankan dashboard:

Library	Versi Minimum	Fungsi
pandas	$\geq 2.0.0$	Manipulasi dan analisis data
numpy	$\geq 1.24.0$	Komputasi numerik
matplotlib	$\geq 3.7.0$	Visualisasi data dasar
seaborn	$\geq 0.12.0$	Visualisasi statistik tingkat tinggi
scikit-learn	$\geq 1.3.0$	Model ML dan preprocessing
scipy	$\geq 1.11.0$	Statistik inferensial (t-test)
streamlit	$\geq 1.28.0$	Framework dashboard interaktif
nbformat	$\geq 5.9.0$	Dukungan Jupyter Notebook

11.4 Alur Deployment

Proses deployment dilakukan melalui tujuh langkah berurutan. Pertama, menjalankan skrip analisis (`burnout_analysis.py` atau notebook) untuk menghasilkan semua artifacts yang diperlukan. Kedua, memverifikasi bahwa seluruh file yang diperlukan (`dashboard_burnout.py`, `model_artifacts.pkl`, `df_clean.csv`, `requirements.txt`) tersedia. Ketiga, menginisialisasi repositori Git dan melakukan commit seluruh file. Keempat, mendorong (push) kode ke repositori GitHub. Kelima, membuka platform Streamlit Cloud di streamlit.io/cloud dan membuat aplikasi baru. Keenam, menghubungkan repositori GitHub dan menentukan file utama sebagai `dashboard_burnout.py`. Ketujuh, mengklik Deploy dan menunggu 2-5 menit hingga dashboard online.

11.5 URL Akses Publik

Setelah deployment berhasil, dashboard dapat diakses secara publik melalui URL yang diberikan oleh Streamlit Cloud dengan format: `https://USERNAME-burnout-prediction-dashboard-burnout-XXXXXX.streamlit.app`. Setiap perubahan pada kode yang di-push ke GitHub akan secara otomatis memicu re-deployment (Continuous Deployment), sehingga pembaruan dapat dilakukan dengan mudah tanpa proses deployment manual yang berulang.

11.6 Integrasi dengan Sistem Lain

Model artifacts yang tersimpan dalam `model_artifacts.pkl` dapat dengan mudah diintegrasikan ke dalam sistem backend seperti FastAPI untuk kebutuhan inference API yang lebih kompleks. Artifacts mencakup seluruh komponen yang diperlukan: model ML, `StandardScaler`, `LabelEncoder` untuk Gender dan JobRole, serta daftar fitur dalam urutan yang benar. Tim AI Engineer dapat memuat artifacts ini dan menggunakannya untuk membangun endpoint prediksi RESTful yang dapat dikonsumsi oleh aplikasi HR enterprise.

BAB 12 -BUSINESS IMPACT

12.1 Implikasi Strategis

Penerapan Burnout Risk Prediction System memiliki potensi dampak bisnis yang signifikan dan terukur. Sistem ini mengubah paradigma manajemen kesehatan karyawan dari pendekatan reaktif menuju pendekatan preventif berbasis data, yang merupakan pergeseran fundamental dalam cara organisasi mengelola aset manusia mereka.

12.2 Dampak Kuantitatif yang Diproyeksikan

Area Dampak	Kondisi Saat Ini	Proyeksi dengan Sistem	Potensi Nilai
Deteksi Burnout	Reaktif -setelah terjadi	Preventif -sebelum terjadi	Mencegah kasus burnout
Biaya Turnover	Tinggi (50–200% gaji tahunan per karyawan)	Berkurang dengan retensi proaktif	Penghematan signifikan
Produktivitas	Turun 30–40% pada karyawan burnout	Intervensi dini mencegah penurunan	Peningkatan output
Program Wellness	Berbasis asumsi, tidak terpersonalisasi	Berbasis data, terpersonalisasi	Efektivitas lebih tinggi

12.3 Nilai untuk Setiap Stakeholder

HR Manager

Dengan menggunakan dashboard Overview dan halaman Explanatory Analysis, HR Manager dapat memantau burnout rate secara keseluruhan, mengidentifikasi departemen atau jabatan dengan risiko tertinggi, dan merancang program wellness yang ditargetkan. Temuan bahwa Sales memiliki burnout rate tertinggi (7,7%) misalnya, dapat mendorong program dukungan psikologis yang spesifik untuk tim Sales.

Manajer Tim

Manajer dapat menggunakan fitur Prediksi Individu untuk mengevaluasi risiko burnout anggota tim mereka dan mendapatkan rekomendasi tindakan yang konkret. Misalnya, jika seorang anggota tim menunjukkan stres level 8 dan jam kerja 60 jam per minggu, sistem akan menandai risiko tinggi dan merekomendasikan pengurangan beban kerja dan sesi konseling.

Karyawan Individual

Karyawan dapat melakukan self-assessment melalui kombinasi kuesioner kepuasan dan stres serta halaman prediksi individu. Sistem memberikan rekomendasi wellness yang dipersonalisasi berdasarkan kondisi spesifik masing-masing karyawan, memberdayakan mereka untuk mengambil tindakan preventif secara mandiri.

12.4 ROI yang Dapat Diestimasi

Jika sistem ini berhasil mengidentifikasi dan mencegah burnout pada 30 persen dari 129 karyawan yang teridentifikasi berisiko (sekitar 38 karyawan), dan mengasumsikan biaya turnover rata-rata sebesar 75 persen dari gaji tahunan, maka penghematan biaya yang dapat diproyeksikan sangat signifikan. Dengan rata-rata gaji karyawan yang diasumsikan, sistem ini dapat memberikan ROI positif bahkan dalam implementasi di skala kecil.

BAB 13 -KESIMPULAN

13.1 Pencapaian Objektif Projek

Projek Burnout Risk Prediction System telah berhasil memenuhi dan bahkan melampaui seluruh objektif yang ditetapkan di awal. Semua target metrik performa model ($\text{Accuracy} \geq 85\%$, $\text{AUC-ROC} \geq 0,85$, $\text{F1-Score} \geq 0,70$) berhasil terlampaui secara signifikan oleh model tree-based yang mencapai performa sempurna pada test set. Sistem prediksi berbasis ML berhasil dibangun, divalidasi melalui cross-validation yang robust, dan di-deploy dalam bentuk dashboard interaktif yang dapat diakses secara publik.

13.2 Temuan Kunci

Tiga temuan kunci yang dihasilkan dari proyek ini memiliki nilai ilmiah dan praktis yang tinggi. Pertama, stres kerja tinggi merupakan faktor risiko burnout yang paling dominan dalam dataset ini ($r = +0,321$), diikuti oleh kepuasan kerja rendah ($r = -0,233$) dan jam kerja panjang ($r = +0,226$). Ketiga faktor ini bertindak sinergis: kombinasi stres tinggi dan jam kerja panjang (HighRiskFlag) terbukti menjadi prediktor tunggal terkuat dengan feature importance mencapai 0,7448 dalam model Decision Tree.

Kedua, tidak ada seorang pun karyawan yang bekerja kurang dari 40 jam per minggu yang mengalami burnout, sementara 13,12% karyawan yang bekerja 50 jam atau lebih mengalami burnout. Perbedaan ini terbukti sangat signifikan secara statistik ($t = 8,72$, $p < 0,001$), memberikan dasar ilmiah yang kuat untuk kebijakan pembatasan jam kerja.

Ketiga, gender dan usia bukanlah prediktor burnout yang signifikan dalam dataset ini ($|r| < 0,02$), mengindikasikan bahwa burnout merupakan fenomena universal yang tidak terkait dengan karakteristik demografis dasar, melainkan lebih terkait dengan kondisi dan lingkungan kerja.

13.3 Keterbatasan Projek

Projek ini memiliki beberapa keterbatasan yang perlu diakui secara jujur. Pertama, dataset yang digunakan adalah dataset sintetis, bukan data karyawan nyata. Meskipun dataset ini dirancang untuk mencerminkan distribusi statistik nyata, pola yang ditemukan mungkin tidak sepenuhnya merepresentasikan kompleksitas kondisi karyawan di dunia nyata dengan segala variabilitas dan noise-nya. Performa model sempurna (1,000) yang diperoleh

mengindikasikan bahwa pola dalam dataset sintetis ini lebih deterministik dibandingkan data nyata.

Kedua, analisis terbatas pada variabel-variabel yang tersedia dalam dataset. Faktor-faktor penting lain yang secara teoritis berkontribusi pada burnout seperti dukungan sosial dari rekan kerja, kualitas kepemimpinan, kejelasan peran, dan faktor kepribadian individu tidak tersedia dalam dataset dan tidak dapat dimasukkan dalam analisis.

BAB 14

REKOMENDASI DAN PERBAIKAN MASA DEPAN

14.1 Rekomendasi untuk Organisasi

14.1.1 Implementasi Kebijakan Jam Kerja

Berdasarkan temuan A/B Testing yang menunjukkan tidak ada burnout pada jam kerja < 40 jam dan burnout rate 13,12% pada ≥ 50 jam, organisasi sebaiknya menetapkan dan menegakkan batas maksimal jam kerja efektif 45-48 jam per minggu, memantau secara aktif karyawan yang secara konsisten melebihi 50 jam per minggu sebagai kelompok prioritas intervensi, serta mengimplementasikan sistem monitoring otomatis yang memberikan peringatan kepada manajer ketika anggota tim melebihi batas jam kerja yang ditetapkan.

14.1.2 Program Manajemen Stres

Mengingat StressLevel adalah prediktor terkuat burnout, organisasi perlu mengimplementasikan program manajemen stres yang komprehensif mencakup workshop reguler tentang teknik mindfulness dan stress management, akses mudah ke layanan konseling profesional, program Employee Assistance Program (EAP), dan mekanisme umpan balik anonim yang memungkinkan karyawan melaporkan beban kerja berlebih tanpa rasa takut.

14.1.3 Peningkatan Kepuasan Kerja

Kepuasan kerja yang rendah merupakan prediktor kuat kedua. Untuk meningkatkannya, organisasi disarankan melakukan survei kepuasan kerja berkala dan anonim, mengimplementasikan program recognition dan reward yang bermakna, memberikan otonomi dan fleksibilitas yang lebih besar dalam cara kerja, serta memastikan adanya jalur karir yang jelas dan peluang pengembangan profesional.

14.1.4 Penggunaan Dashboard sebagai Alat Monitoring

Dashboard yang telah dikembangkan sebaiknya diintegrasikan ke dalam sistem HR sebagai alat monitoring rutin. Disarankan untuk melakukan pembaruan data secara berkala (misalnya bulanan atau triwulanan) dengan data karyawan aktual, menggunakan halaman Prediksi Individu sebagai bagian dari proses onboarding dan evaluasi karyawan, serta

memanfaatkan halaman A/B Testing untuk mengevaluasi efektivitas intervensi wellness yang telah diimplementasikan.

14.2 Rekomendasi Teknis untuk Tim Data Science

1. Pengembangan pada Data Nyata: Melatih ulang model menggunakan data karyawan nyata yang telah dilindungi anonimitasnya untuk mendapatkan model yang lebih robust dan representatif terhadap dinamika burnout di dunia nyata.
2. Penambahan Fitur: Memperluas dataset dengan variabel-variabel tambahan yang relevan seperti frekuensi pertemuan (meeting), indeks kualitas kepemimpinan, ketersediaan akses ke layanan kesehatan mental, dan metrik kinerja objektif.
3. Model Lebih Canggih: Mengeksplorasi model yang lebih kompleks seperti XGBoost, LightGBM, atau Neural Network untuk data nyata yang memiliki pola yang lebih kompleks dan non-deterministik.
4. Explainability: Mengintegrasikan tools explainability seperti SHAP (SHapley Additive exPlanations) atau LIME (Local Interpretable Model-agnostic Explanations) untuk memberikan penjelasan yang lebih transparan tentang mengapa seorang karyawan tertentu diprediksi berisiko tinggi.
5. Monitoring Produksi: Mengimplementasikan sistem monitoring data drift dan model drift untuk mendeteksi degradasi performa model seiring berjalannya waktu dan perubahan pola data.
6. Pemrosesan Data Real-time: Mengembangkan pipeline data real-time yang terintegrasi dengan sistem HRIS (Human Resource Information System) untuk memperbarui prediksi risiko secara otomatis tanpa intervensi manual.
7. Privasi dan Etika: Memastikan implementasi yang mematuhi regulasi privasi data yang berlaku (GDPR, UU Perlindungan Data Pribadi Indonesia), termasuk persetujuan karyawan, transparansi tentang penggunaan data, dan mekanisme opt-out.

14.3 Future Improvements Dashboard

Beberapa fitur tambahan yang dapat meningkatkan nilai dashboard secara signifikan di masa mendatang meliputi: integrasi notifikasi email otomatis untuk reminder burnout check, fitur export laporan dalam format PDF untuk keperluan HR, perbandingan historis untuk memantau tren risiko burnout dari waktu ke waktu, fitur benchmarking antar departemen atau

tim, dan integrasi dengan platform komunikasi internal seperti Slack atau Microsoft Teams untuk pengiriman alert otomatis.

APPENDIX

A. Dataset Summary

Atribut	Detail
Nama File	synthetic_employee_burnout.csv
Jumlah Baris	2.000 karyawan
Jumlah Kolom Original	10 (termasuk Name)
Kolom yang Dihapus	Name (identifikasi tidak informatif)
Jumlah Kolom Aktif	9 (setelah hapus Name)
Jumlah Kolom Rekayasa	9 (RiskLevel, Gender_enc, JobRole_enc, StressWorkRatio, WorkLifeScore, HighRiskFlag, SeniorEmployee, StressCategory, SatisfactionInverse)
Total Kolom Dataset Akhir	18 kolom
Missing Values	0 (tidak ada)
Duplikat	0 (tidak ada)
Class Imbalance	93,5% tidak burnout : 6,5% burnout
Burnout Rate	6,5% (129 dari 2.000 karyawan)

B. Data Dictionary Lengkap

Kolom	Tipe	Jenis	Rentang	Deskripsi
Age	int	Original	22–60	Usia karyawan dalam tahun
Gender	str	Original	Male/Female	Jenis kelamin karyawan
JobRole	str	Original	5 kategori	Posisi jabatan: Analyst, Engineer, HR, Manager, Sales

Experience	int	Original	0–39	Lama pengalaman kerja dalam tahun
WorkHoursPerWeek	int	Original	30–70	Rata-rata jam kerja per minggu
RemoteRatio	int	Original	0–100%	Persentase waktu kerja remote
SatisfactionLevel	float	Original	1,0–5,0	Skor kepuasan kerja (1=sangat tidak puas, 5=sangat puas)
StressLevel	int	Original	1–10	Tingkat stres kerja
Burnout	int	Target	0/1	0 = Tidak Burnout, 1 = Burnout
RiskLevel	str	Rekayasa	3 kelas	Klasifikasi risiko: Rendah/Sedang/Tinggi
Gender_enc	int	Rekayasa	0/1	Female=0, Male=1
JobRole_enc	int	Rekayasa	0–4	Label encoding jabatan
StressWorkRatio	float	Rekayasa	>0	$\text{StressLevel} / (\text{WorkHoursPerWeek} + 1)$
WorkLifeScore	float	Rekayasa	0–5	$\text{SatisfactionLevel} \times (1 - \text{RemoteRatio}/100)$
HighRiskFlag	int	Rekayasa	0/1	1 jika $\text{StressLevel} \geq 7$ DAN $\text{WorkHoursPerWeek} \geq 50$
SeniorEmployee	int	Rekayasa	0/1	1 jika $\text{Experience} \geq 10$ tahun
StressCategory	int	Rekayasa	0/1/2	Kategori stres: 0=Rendah, 1=Sedang, 2=Tinggi
SatisfactionInverse	float	Rekayasa	0–4	$5,0 - \text{SatisfactionLevel}$

C. Konfigurasi Model

Model	Parameter Konfigurasi	Catatan
-------	-----------------------	---------

Logistic Regression	max_iter=1000, class_weight='balanced', random_state=42	Baseline model, interpretatif
Decision Tree	max_depth=5, class_weight='balanced', random_state=42	Model terpilih (AUC-ROC = 1,000)
Random Forest	n_estimators=100, class_weight='balanced', n_jobs=-1, random_state=42	Ensemble bagging, robust
Gradient Boosting	n_estimators=100, random_state=42	Ensemble boosting, sequential

D. Hasil Evaluasi Model Lengkap

Model	Accuracy	F1	Precision	Recall	AUC-ROC	CV F1	CV Std
Logistic Regression	0,9525	0,7324	0,5778	1,0000	0,9937	0,7482	0,0204
Decision Tree	1,0000	1,0000	1,0000	1,0000	1,0000	0,9961	0,0078
Random Forest	1,0000	1,0000	1,0000	1,0000	1,0000	0,9961	0,0078
Gradient Boosting	1,0000	1,0000	1,0000	1,0000	1,0000	0,9961	0,0078

E. Ringkasan A/B Testing

Test	Kelompok A	Kelompok B	t-statistic	p-value	Keputusan
------	------------	------------	-------------	---------	-----------

Test 1: LR vs RF	LR Mean F1=0,748	RF Mean F1=0,996	Sangat tinggi	< 0,05	TOLAK H0 - RF lebih baik
Test 2: RF vs GB	RF Mean F1=0,996	GB Mean F1=0,996	~0	> 0,05	GAGAL TOLAK H0 - setara
Test 3: Jam Kerja	<40 jam: burnout 0,00%	≥50 jam: burnout 13,12%	8,7194	< 0,001	TOLAK H0 - sangat signifikan

F. Struktur File Proyek

File	Ukuran	Fungsi
burnout_analysis.py	56 KB	Pipeline analisis utama -menjalankan seluruh tahapan dari data loading hingga model training
burnout_analysis.ipynb	76 KB	Versi Jupyter Notebook interaktif dengan penjelasan di setiap cell
dashboard_burnout.py	64 KB	Aplikasi dashboard Streamlit dengan 9 halaman navigasi
synthetic_employee_burnout.csv	88 KB	Dataset mentah -2.000 baris, 10 kolom
df_clean.csv	80 KB	Dataset bersih hasil data wrangling - 2.000 baris, 10 kolom aktif
data_dictionary.csv	1,4 KB	Kamus data lengkap dalam format CSV
model_artifacts.pkl	4,1 KB	Model ML, scaler, encoder, dan metadata tersimpan dalam format pickle
requirements.txt	130 bytes	Daftar dependensi Python beserta versi minimum

fig1_distribusi_fitur.png	233 KB	Visualisasi distribusi 6 fitur utama berdasarkan status burnout
fig2_heatmap_korelasi.png	82 KB	Heatmap korelasi antar fitur numerik
fig3_burnout_kategori.png	64 KB	Burnout rate per JobRole dan Gender
fig4_boxplot_burnout.png	83 KB	Boxplot perbandingan distribusi burnout vs tidak burnout
fig5_risk_level.png	82 KB	Distribusi Risk Level (pie + bar chart)
fig6_scatter_burnout.png	245 KB	Scatter plot WorkHours vs Stress dan Satisfaction vs Stress
fig7_explanatory.png	275 KB	Ringkasan 7 Business Questions dalam satu panel
fig8_ab_testing.png	106 KB	Visualisasi hasil A/B Testing

—Akhir Laporan—